

**МИНОБРНАУКИ РОССИИ**  
**САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ**  
**ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ**  
**«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)**  
**КАФЕДРА МО ЭВМ**

**ОТЧЕТ**  
**по лабораторной работе №4**  
**по дисциплине «Построение и Анализ Алгоритмов»**  
**Тема: Алгоритм Кнута-Морриса-Пратта**

Студент гр. 1303

\_\_\_\_\_

Смирнов Д. Ю.

Преподаватель

\_\_\_\_\_

Фирсов М. А.

Санкт-Петербург

2023

### Цель работы.

Реализовать алгоритм Кнута-Морриса-Пратта для нахождения вхождений одной подстроки в другую и для определения, является ли одна строка циклическим сдвигом другой.

### Задание.

1. Реализуйте алгоритм КМП и с его помощью для заданных шаблона  $P$  ( $|P| \leq 15000$ ) и текста  $T$  ( $|T| \leq 5000000$ ) найдите все вхождения  $P$  в  $T$ .

Вход:

Первая строка -  $P$

Вторая строка -  $T$

Выход:

индексы начал вхождений  $P$  в  $T$ , разделенных запятой, если  $P$  не входит в  $T$ , то вывести  $-1$

---

#### Sample Input:

ab  
abab

---

#### Sample Output:

0, 2

2. Заданы две строки  $A$  ( $|A| \leq 5000000$ ) и  $B$  ( $|B| \leq 5000000$ ). Определить, является ли  $A$  циклическим сдвигом  $B$  (это значит, что  $A$  и  $B$  имеют одинаковую длину и  $A$  состоит из суффикса  $B$ , склеенного с префиксом  $B$ ). Например, defabc является циклическим сдвигом abcdef.

Вход:

Первая строка -  $A$

Вторая строка -  $B$

Выход:

Если  $A$  является циклическим сдвигом  $B$ , индекс начала строки  $B$  в  $A$ , иначе вывести  $-1$ . Если возможно несколько сдвигов вывести первый индекс.

---

**Sample Input:**

```
defabc  
abcdef
```

---

**Sample Output:**

```
3
```

### **Выполнение работы.**

Весь код программ представлен в приложении А.

### **Описание алгоритма.**

#### Префикс-функция:

В функции создается список *result* и переменная *j* – она будет использоваться для отслеживания длины текущего совпадающего префикса и суффикса. Далее проходимся по индексам (*i*) строки, начиная с единицы, до длины паттерна. При совпадении символов *pattern[i]* и *pattern[j]* увеличиваем значение *j* на 1 и затем записываем значение *j* в список *result* по индексу *i*. В случае несовпадения символов, значение *j* обновляется на значение *result[j-1]* – это позволяет алгоритму вернуться к предыдущему совпадающему префиксу и суффиксу. Как только дошли до конца строки возвращаем список *result* в качестве результата функции.

#### Алгоритм Кнута-Морриса-Пратта:

Для искомой подстроки вызывается префикс-функция.

Инициализируем пустой список *result* для индексов вхождений образца в тексте, переменную *i*, отслеживающую длину совпадающего префикса образца и текста, *j* – индекс в тексте. Далее пока не дошли до конца текста, если текущие символы (*pattern[i]* и *text[j]*) совпадают, увеличиваем *j* и *i* на 1. В случае, если *i* равно длине подстроки, значит подстрока найдена в тексте - добавляем индекс начала вхождения подстроки в текст в список *result*, также устанавливаем *i* равным значению префикс-функции для последнего символа образца. Если же символы (*pattern[i]* и *text[j]*) не совпадают и *i* > 0, то уменьшаем *i* (устанавливаем *i* равным значению префикс-функции для предыдущего символа). В конце возвращаем список индексов вхождений образца в текст.

## Описание переменных и функций.

Глобальные переменные:

- *DEBUG* – Флаг отвечающий за вывод дополнительной информации.

Функции:

- *prefixFunction(pattern: str) -> list* – Функция отвечает за выполнение описанной выше префикс-функции. Аргумент *pattern* – строка, для которой хотят построить префикс-функцию. Функция возвращает список из длин префиксов.
- (Для задания 1) *algorithmKMP(pattern: str, text: str) -> list* – Функция отвечает за описанный выше алгоритм КМП. Аргументы: *pattern* – строка, вхождения которой хотят найти в тексте, *text* – строка, в которой ищут все вхождения *pattern*'а. Функция возвращает список из индексов вхождения *pattern*'а в *text*.
- (Для задания 2) *algorithmKMP(pattern: str, text: str) -> list* – Функция отвечает за описанный выше алгоритм КМП, но после того как нашло первое вхождение выходит из функции, если дошли до конца строки и вхождение не было найдено, то возвращаем *-1*. Аргументы: *pattern* – строка, вхождения которой хотят найти в тексте, *text* – строка, в которой ищут все вхождения *pattern*'а. Функция возвращает список из индексов вхождения *pattern*'а в *text*.

Для решения 2-го задания алгоритм КМП выполняется для удвоенной строки *A*, так как если она является циклическим сдвигом строки *B*, то в ней точно будет содержаться подстрока *B*.

### **Оценка сложности алгоритмов.**

#### Префикс-функция:

Для построения списка длин наибольших префиксов для каждой позиции этой строки, функция проходится по всей строке, из-за чего сложность будет  $O(n)$ , где  $n$  – длина строки.

#### Алгоритм Кнута-Морриса-Пратта:

Для искомой подстроки выполняется префикс функция. После чего функция проходится по всему тексту из чего следует сложность  $O(n + m)$ , где  $n$  – длина подстроки,  $m$  – длина текста. По памяти имеем 2 строки, из чего получаем  $O(n + m)$ , где  $n$  – длина подстроки,  $m$  – длина текста.

### Тестирование.

Пример вывода дополнительной информации для заданий 1-2, представлен на рисунках 1-2 соответственно.

Тестирование Префикс-функции:

Входные данные	Выходные данные	Комментарий
efefeftefe	0 0 1 2 3 4 0 1 2 3	Верно
abcde	0 0 0 0 0	Верно
aba	0 0 1	Верно

Тестирование алгоритма Кнута-Морриса-Пратта:

Входные данные	Выходные данные	Комментарий
smth nothing	-1	Верно
aba abababF	0,2	Верно
lip liliput	2	Верно
abba abba	0	Верно
avav avavavava	0,2,4	Верно
abbb vv	-1	Верно

Тестирование алгоритма определения циклического сдвига:

Входные данные	Выходные данные	Комментарий
defabc abcdef	3	Верно

ab abc	-1	Верно
abc ab	-1	Верно
abc bca	1	Верно
abc cab	2	Верно
abc abc	0	Верно



```
aba
ababa
Суффикс/префикс на текущей итерации не найден (a != b):
Записываем значение result[1]=0
Идем к следующему символу

Символы (a) совпали на индексах j=0 i=2
Текущий префикс/суффикс: a
Записываем значение result[2]=1
[0, 0, 1]

Массив префикс функции
[0, 0, 1]

ИНИЦИАЛИЗАЦИЯ АЛГОРИТМА КМП:
result=[], i=0, j=0

Символы (a) совпали на индексах i=0 j=0
Текущий вхождение имеет вид: a

Символы (b) совпали на индексах i=1 j=1
Текущий вхождение имеет вид: ab

Символы (a) совпали на индексах i=2 j=2
Текущий вхождение имеет вид: aba

Нашли вхождение
На индексе: 0
Начинаем проверять с префикса: a

Символы (b) совпали на индексах i=1 j=3
Текущий вхождение имеет вид: ab

Символы (a) совпали на индексах i=2 j=4
Текущий вхождение имеет вид: aba

Нашли вхождение
На индексе: 2
Начинаем проверять с префикса: a

0,2
```

Рисунок 1- дополнительный вывод для задания 1

```
baa
aab
Символы (a) совпали на индексах j=0 i=1
Текущий префикс/суффикс: a
Записываем значение result[1]=1
[0, 1, 0]

Рассматриваем предыдущую длину: 0

Суффикс/префикс на текущей итерации не найден (a != b):
Записываем значение result[2]=0
Идем к следующему символу

Массив префикс функции
[0, 1, 0]

ИНИЦИАЛИЗАЦИЯ АЛГОРИТМА КМП:
pattern=aab, text=baabaa, i=0, j=0

Символ (b) не является началом вхождения подстроки, идем к следующему символу строки

Символы (a) совпали на индексах i=0 j=1
Текущий вхождение имеет вид: a

Символы (a) совпали на индексах i=1 j=2
Текущий вхождение имеет вид: aa

Символы (b) совпали на индексах i=2 j=3
Текущий вхождение имеет вид: aab

Нашли вхождение
На индексе: 1
Выходим из функции

1
```

Рисунок 2- дополнительный вывод для задания 2

### **Вывод.**

В ходе выполнения лабораторной работы изучен принцип работы префикс функции, а также алгоритм Кнута-Морриса-Пратта — поиска вхождения подстроки в строку. Разработаны две программы, первая: нахождения всех вхождений подстроки в строку, вторая: проверяющая является ли строка циклическим сдвигом другой.

## ПРИЛОЖЕНИЕ А

### ИСХОДНЫЙ КОД ПРОГРАММ

Название файла: KMPAlgorithm.py

DEBUG = True

```
def prefixFunction(pattern: str) -> list:
    """
        Функция принимает на вход строку и высчитывает для каждой
        подстроки [1...i]
        значение префикс-функции. При этом на каждом шаге используется
        информация
        о длине максимального префикса на предыдущем шаге, что ускоряет
        подсчёт.
        :param pattern: строка для которой вычисляют префикс функцию
        :return: массив из элементов, обозначающих длину максимального
        префикса строки, совпадающего с её суффиксом
    """
    global DEBUG
    result = [0] * len(pattern)

    j, i = 0, 1
    while i < len(pattern):
        if pattern[i] == pattern[j]: # символы совпали
            result[i] = j + 1 # увеличиваем текущую длину
            if DEBUG:
                print(f"Символы ({pattern[i]}) совпали на индексах
j={j} i={i}")
                print(f"Текущий префикс/суфикс: {pattern[:j + 1]}")
                print(f"Записываем значение result[{i}]= {j + 1}")
                print(result, end="\n\n")
            j += 1 # увеличиваем индексы
            i += 1
        else:
            if j == 0:
                if DEBUG:
                    print(f"Суфикс/префикс на текущей итерации не
найден ({pattern[j]} != {pattern[i]}):")
                    print(f"Записываем значение result[{i}]=0")
                    print("Идем к следующему символу")
                    print("\n")
                result[i] = 0 # сопадений нет
                i += 1 # к следующему символу
            else:
                if DEBUG:
                    print(f"Рассматриваем предыдущую длину:
{result[j - 1]}")
                    print("\n")
                j = result[j - 1] # возвращаемся с предыдущей длине
    if DEBUG:
        print("Массив префикс функции")
        print(result, end="\n\n")
    return result
```

```

def algorithmKMP(pattern: str, text: str) -> list:
    """
    Посредством посимвольного сравнения двух строк определяются
    совпадение подстроки pattern
    со строкой text. Если все символы совпали - вхождение найдено
    и в результат записывается индекс вхождения.
    Если первые символы не совпали, то первый символ pattern
    сравнивается со вторым text и так далее до попадания. Если
    символ pattern не совпадает с символом text, то следующее
    сравнение происходит
    с символом подстроки P под индексом префикс-функции предыдущего
    символа.
    Эти действия будут повторяться до тех пор, пока не будет
    достигнут последний символ строки text.
    :param pattern: подстрока, вхождение которой ищут
    :param text: строка в которой ищут вхождение
    :return: список индексов вхождений
    """
    global DEBUG
    prefArray = prefixFunction(pattern)
    result = []
    i = 0
    j = 0
    if DEBUG:
        print("ИНИЦИАЛИЗАЦИЯ АЛГОРИТМА КМП:")
        print(f"result={result}, i={i}, j={j}\n")
    while j < len(text):
        if pattern[i] == text[j]: # символы совпали
            if DEBUG:
                print(f"Символы ({pattern[i]}) совпали на индексах
i={i} j={j}")
                print(f"Текущий вхождение имеет вид: {pattern[:i +
1]}\n")
            i += 1 # идем дальше
            j += 1
        if i == len(pattern): # нашли вхождение
            if DEBUG:
                print("Нашли вхождение")
                print(f"На индексе: {j - i}")
                print(f"Начинаем проверять с префикса:
{pattern[:prefArray[i - 1]]}\n")
            result.append(j - i) # сохраняем его индекс
            i = prefArray[i - 1] # восстанавливаем индекс паттерна
        elif j < len(text) and pattern[i] != text[j]: # пока не
дошли до конца и не совпали символы
            if i == 0:
                if DEBUG:
                    print(f"Символ ({text[j]}) не является началом
вхождения подстроки, идем к следующему символу строки\n")
                j += 1 # идем к следующему
            else:
                if DEBUG:
                    print(f"Рассматриваем предыдущую длину:
{prefArray[i - 1]}\n")
                i = prefArray[i - 1] # восстанавливаем индекс
паттерна
    return result

```

```

def main():
    answer = algorithmKMP(input(), input()) # Считываем входные
    данные и запускаем алгоритм КМП
    print(','.join(map(str, answer if answer else [-1]))) # если
    нашли хоть один индекс выводим его, иначе -1

if __name__ == "__main__":
    main()

```

Название файла: `binaryHeap.py`

```

class Heap:
    def __init__(self, arr=None):
        "Инициализация объекта класса"
        if arr is None:
            arr = []
        self.__heap = []
        for el in arr:
            self.insert(el)

    @staticmethod
    def getParent(index):
        "Получение индекса родителя текущей вершины"
        return (index - 1) // 2

    @staticmethod
    def getLeft(index):
        "Получение индекса левого ребенка"
        return 2 * index + 1

    @staticmethod
    def getRight(index):
        "Получение индекса правого ребенка"
        return 2 * index + 2

    def __siftUp(self, index):
        """
        Просеивает вверх узел
        :param index: индекс вершины которую хотят просеять вверх
        :return: ничего возвращает
        """
        if index < 0 or index >= len(self.__heap):
            return
        parent = self.getParent(index)
        while index and not self.__heap[parent] < self.__heap[index]:
            self.__heap[parent], self.__heap[index] =
self.__heap[index], self.__heap[parent]
            index, parent = parent, self.getParent(index)

    def __siftDown(self, index):
        """
        Просеивает вниз узел
        :param index: индекс вершины которую хотят просеять вниз
        :return: ничего возвращает
        """

```

```

        if index < 0 or index >= len(self.__heap):
            return
        minIndex = index
        while True:
            left, right = self.getLeft(index), self.getRight(index)
            if right < len(self.__heap) and self.__heap[right] <
self.__heap[minIndex]:
                minIndex = right
            if left < len(self.__heap) and self.__heap[left] <
self.__heap[minIndex]:
                minIndex = left
            if minIndex == index:
                return
            else:
                self.__heap[index], self.__heap[minIndex] =
self.__heap[minIndex], self.__heap[index]
                index = minIndex

    def extract_min(self):
        """
        Достает минимальный ставит максимальный на его место и
        просеивает вниз.
        :return: возвращает минимальный элемент
        """
        if not self.__heap:
            return
        min_element = self.__heap[0]
        self.__heap[0] = self.__heap[-1]
        del self.__heap[-1]
        self.__siftDown(0)
        return min_element

    def insert(self, element):
        """
        Добавляет элемент ставит в конец и просеивает вверх его.
        :return: ничего возвращает
        """
        self.__heap.append(element)
        self.__siftUp(len(self.__heap) - 1)

    def size(self):
        """
        :return: возвращает размер кучи
        """
        return len(self.__heap)

    def __repr__(self):
        representation = ""
        for item in self.__heap:
            representation += '\t' + str(item) + "\n"
        return representation

```

**Название файла:** cycleShift.py

DEBUG = True

```

def prefixFunction(pattern: str) -> list:
    """

```

Функция принимает на вход строку и высчитывает для каждой подстроки [1...i] значение префикс-функции. При этом на каждом шаге используется информация о длине максимального префикса на предыдущем шаге, что ускоряет подсчёт.

```

:param pattern: строка для которой вычисляют префикс функцию
:return: массив из элементов, обозначающих длину максимального
префикса строки, совпадающего с её суффиксом
"""
global DEBUG
size = len(pattern)
result = [0] * size

j, i = 0, 1
while i < size:
    if pattern[i] == pattern[j]: # символы совпали
        result[i] = j + 1 # увеличиваем текущую длину
        if DEBUG:
            print(f"Символы ({pattern[i]}) совпали на индексах
j={j} i={i}")
            print(f"Текущий префикс/суфикс: {pattern[:j + 1]}")
            print(f"Записываем значение result[{i}]=j + 1")
            print(result, end="\n\n")
            j += 1 # увеличиваем индексы
            i += 1
    else:
        if j == 0:
            if DEBUG:
                print(f"Суфикс/префикс на текущей итерации не
найден ({pattern[j]} != {pattern[i]}):")
                print(f"Записываем значение result[{i}]=0")
                print("Идем к следующему символу")
                print("\n")
                result[i] = 0 # сопадений нет
                i += 1 # к следующему символу
            else:
                if DEBUG:
                    print(f"Рассматриваем предыдущую длину:
{result[j - 1]}")
                    print("\n")
                    j = result[j - 1] # возвращаемся с предыдущей длине
                if DEBUG:
                    print("Массив префикс функции")
                    print(result, end="\n\n")
        return result

```

```

def algorithmKMP(pattern: str, text: str) -> int:
    """

```

Посредством посимвольного сравнения двух строк определяются совпадение подстроки pattern со строкой text. Если все символы совпали - вхождение найдено и в результат возвращается. Если первые символы не совпали, то первый символ pattern сравнивается со вторым text и так далее до попадания. Если символ pattern не совпадает с символом text, то следующее



сравнение происходит

с символом подстроки *P* под индексом префикс-функции предыдущего символа.

Эти действия будут повторяться до тех пор, пока не будет достигнут последний символ строки *text*.

**:param** pattern: подстрока, вхождение которой ищут

**:param** text: строка в которой ищут вхождение

**:return:** список индексов вхождений

"""

```
global DEBUG
patternSize, textSize = len(pattern), len(text)
prefArray = prefixFunction(pattern)
i = 0
j = 0
if DEBUG:
    print("ИНИЦИАЛИЗАЦИЯ АЛГОРИТМА КМП:")
    print(f"pattern={pattern}, text={text}, i={i}, j={j}\n")
while j < textSize:
    if pattern[i] == text[j]: # символы совпали
        if DEBUG:
            print(f"Символы ({pattern[i]}) совпали на индексах
i={i} j={j}")
            print(f"Текущий вхождение имеет вид: {pattern[:i +
1]}\n")
            i += 1 # идем дальше
            j += 1
            if i == patternSize: # нашли вхождение
                if DEBUG:
                    print("Нашли вхождение")
                    print(f"На индексе: {j - i}")
                    print(f"Выходим из функции\n")
                return j - i # прекращаем поиск вывода индекс
            else:
                if i == 0:
                    if DEBUG:
                        print(f"Символ ({text[j]}) не является началом
вхождения подстроки, идем к следующему символу строки\n")
                    j += 1 # идем к следующему
                else:
                    if DEBUG:
                        print(f"Нашли различные символы ({pattern[i]} !=
{text[j]}) и i({i})>0 из-за чего")
                        print(f"Рассматриваем предыдущую длину:
{prefArray[i - 1]}\n")
                    i = prefArray[i - 1] # восстанавливаем индекс
паттерна
            if DEBUG:
                print("text - не является циклической престановкой,")
                print("возвращаем -1")
        return -1

def main():
    # считываем данные
    text = input()
    pattern = input()
    # если разная длина выводим сразу ответ
```

```
if len(text) != len(pattern):  
    print(-1)  
    return  
# иначе запускаем алгоритм КМП для склеенного текста  
print(algorithmKMP(pattern, text * 2))  
  
if __name__ == "__main__":  
    main()
```